


Colon Cancer Classification



Plan



1. Introduction

4. Utilisation d'un Modèle Pré-entraîné



2. Jeux de Données et Prétraitement


5. Comparaison des Deux Approches

3. Application d'un CNN


6. Démonstration en Temps Réel (Lab)

7. Conclusion et Perspectives





Introduction




Contexte et motivation du projet




Le cancer du côlon est parmi les cancers les plus mortels dans le monde.

Une détection précoce peut considérablement améliorer les chances de survie des patients.


L'intelligence artificielle, notamment les réseaux de neurones convolutifs (CNN), offre des solutions prometteuses pour automatiser la détection à partir d'images médicales.




Objectifs du projet




Développer un modèle de classification d'images pour détecter la présence d'un cancer.




Comparer un modèle CNN conçu from scratch à un modèle pré-entraîné.



Analyser les performances et déterminer l'approche la plus efficace pour une application clinique.





2. Jeux de Données et Prétraitement




Présentation du dataset :


- **Source :** Les données utilisées proviennent du dataset Colon Cancer Histopathological Images disponible sur Kaggle. Elles contiennent des images classées en "bénin" et "malin".
- **Type d'images :** Images histopathologiques en format JPEG, dimensions 768x768 pixels.
- **Classes :** Images de tissus sains vs images de tissus cancéreux.
 1. Adénocarcinome colique (*5000 images*)
 2. Tissu colique sain (*5000 images*)




Prétraitement des images :

- **Redimensionnement :** Toutes les images sont redimensionnées à 224x224 pixels.
- **Normalisation :** Mise à l'échelle des pixels entre [0,1] (rescale=1./255).
- **Augmentation de données (train uniquement) :**
 - 1.Rotation
 - 2.zoom
 - 3.flip
- **Échantillon initial :** 500 images (250 colon polipos coliques bénins, 250 adénocarcinomes coliques).
- L'augmentation des données est faite à l'aide du package Augmentor, portant ainsi le total à 25 000 images, réparties également entre les 2 classes (5 000 images par classe) :
 - a. Colon adenocarcinoma
 - b. Colon benign tissue





Approche 1 - CNN From Scratch



Modèle CNN :

Architecture du modèle CNN

l'architecture du réseau de neurones convolutifs (CNN) est constituée des éléments suivants :

- **Conv2D Layers :** Le modèle comprend cinq blocs convolutionnels utilisant des filtres de taille 3x3 avec l'activation ReLU et une normalisation par lot (BatchNormalization). Ces couches sont responsables de l'extraction des caractéristiques locales des images.
 - Première couche convolutionnelle : 16 filtres, avec normalisation et un pooling 2x2.
 - Deuxième couche convolutionnelle : 32 filtres.
 - Troisième couche convolutionnelle : 64 filtres.
 - Quatrième couche convolutionnelle : 128 filtres.
 - Cinquième couche convolutionnelle : 256 filtres.
- Après chaque couche de convolution, une couche de MaxPooling2D (2x2) est appliquée pour réduire la dimensionnalité des cartes de caractéristiques tout en préservant l'information essentielle.

Modèle CNN :

- **Couches Denses (Dense Layers) :** Une couche Flatten est utilisée pour transformer les cartes de caractéristiques multidimensionnelles en un vecteur 1D, afin qu'elles puissent être utilisées par les couches entièrement connectées. Le modèle contient trois couches denses, chacune suivie d'une technique de régularisation Dropout pour éviter le surapprentissage (overfitting) :

- Première couche dense : 128 neurones, avec un Dropout de 50 %.
- Deuxième couche dense : 64 neurones, avec un Dropout de 30 %.
- Troisième couche dense : 32 neurones, avec un Dropout de 20 %.

Sortie du Modèle : La couche de sortie est une couche dense utilisant une activation sigmoïde (sigmoid), adaptée pour une classification multi-classe binaire.

Justification du choix des hyperparamètres :

- **Taille des filtres (3x3) :**

- Ce choix est optimal pour capturer des motifs locaux dans les images tout en maintenant une complexité computationnelle raisonnable.
- Cette taille est un standard dans les CNN modernes, car elle permet d'extraire efficacement les contours et textures tout en facilitant l'optimisation du modèle.

- **Nombre de filtres (16, 32, 64, 128, 256) :**

- Cela permet d'extraire des caractéristiques de plus en plus abstraites et complexes à chaque couche
- Les premières couches capturent des caractéristiques générales (bords, textures), tandis que les couches profondes détectent des motifs plus spécifiques (formes complexes).
- L'augmentation progressive des filtres équilibre la performance et la charge computationnelle :
 - Trop de filtres dès le début augmenterait le risque d'overfitting et la complexité du modèle.
 - Trop peu de filtres dans les couches profondes limiterait la capacité d'apprentissage du modèle.

Justification du choix des hyperparamètres :

- **MaxPooling2D :**
 - De réduire le nombre de paramètres, ce qui diminue la charge computationnelle.
 - D'extraire des caractéristiques plus globales et d'améliorer la généralisation.
 - D'atténuer le risque d'overfitting en conservant uniquement les informations les plus importantes.
- **Dropout (0.5, 0.3, 0.2)**
 - Taux de Dropout de 50 % dans la première couche dense :
 - Ce taux élevé permet de réduire l'overfitting, surtout dans les premières couches entièrement connectées où les paramètres sont nombreux.
 - Taux de Dropout de 30 % et 20 % dans les couches suivantes :
 - Un taux plus faible dans les dernières couches permet de préserver plus d'informations pour la classification finale.
 - Cette approche empêche le modèle de trop s'appuyer sur certaines connexions spécifiques, ce qui améliore la généralisation.
- **MaxPooling2D :**
 - Utilisation de l'activation sigmoïde (sigmoid) pour la classification multi-classe binaire.
 - Adaptée lorsque chaque classe est considérée indépendamment (classification multilabel).
 - Elle permet d'obtenir une probabilité pour chaque classe, ce qui est utile pour des décisions interprétables.


Entraînement du Modèle :

L'entraînement du modèle est réalisé sur 20 époques, permettant au réseau de s'ajuster progressivement aux données.

- **Epochs** : Le modèle est entraîné sur 20 époques complètes, offrant suffisamment d'itérations pour apprendre des caractéristiques pertinentes tout en évitant un entraînement excessif.
- **Validation** : À chaque époque, les performances du modèle sont évaluées sur l'ensemble de validation pour suivre son évolution et détecter un éventuel surapprentissage.
- **Shuffling** : L'option shuffle=False garantit que l'ordre des échantillons n'est pas modifié à chaque époque, ce qui peut être utile selon la structure des données et la méthode d'augmentation appliquée.

Résultats et évaluation :

- **Accuracy** : mesure la proportion de prédictions correctes.
- **F1 Score** : combine précision et rappel pour évaluer la performance en cas de déséquilibre des classes.
- **matrice de confusion** : affiche les erreurs du modèle en termes de vrais/faux positifs et négatifs.




Avantages et limites du CNN :

Avantages :


- Les CNN sont très efficaces pour les tâches de classification d'images grâce à leur capacité à extraire des caractéristiques locales et à s'adapter à des variations spatiales dans les images.
- Ils sont relativement peu sensibles à la mise à l'échelle et à la translation des objets dans les images.
- L'utilisation de techniques comme le Dropout et la régularisation peut aider à prévenir le surapprentissage, ce qui améliore la généralisation du modèle.

Limites :

- La complexité computationnelle peut être élevée, surtout pour des images de grande taille et des modèles profonds.
- Un grand nombre d'époques peut être nécessaire pour bien entraîner le modèle, ce qui peut entraîner un temps d'entraînement long.
- Si les données d'entraînement sont limitées ou non équilibrées, le modèle risque de sur-apprendre certaines classes et de ne pas bien généraliser.



Utilisation d'un Modèle Pré-entraîné



Présentation du modèle préentraîné sélectionné :

- Dans cette approche, nous avons choisi d'utiliser un modèle préentraîné pour tirer parti de la puissance de réseaux neuronaux déjà formés sur de vastes ensembles de données.
- Les modèles populaires que nous avons envisagés sont :
 - **ResNet** : Un modèle basé sur des connexions résiduelles qui permet d'éviter le problème de la dégradation des performances dans les réseaux très profonds.
 - **VGG** : Un réseau relativement simple mais efficace, qui utilise des couches convolutives profondes avec de petites fenêtres (3x3) pour extraire des caractéristiques.
 - **EfficientNet** : Un modèle qui optimise la taille du réseau, la profondeur et la résolution de l'entrée, offrant un compromis entre la précision et l'efficacité.
- Ces modèles ont été préentraînés sur de grandes bases de données d'images comme ImageNet, ce qui permet d'extraire des caractéristiques pertinentes pour la classification d'images médicales.

Stratégie de fine-tuning et d'extraction de caractéristiques :



- Le fine-tuning consiste à adapter un modèle pré-entraîné en ajustant certaines couches afin qu'il soit optimisé pour une tâche spécifique. Dans notre cas, nous exploitons EfficientNetB3, un modèle de classification d'images pré-entraîné sur ImageNet, pour la classification d'images médicales. En pratique :
 - **Gel des couches initiales :** Nous gelons les premières couches du modèle préentraîné, qui ont appris des caractéristiques génériques comme les bords et les textures.
 - **Ajout de couches spécifiques :** Nous ajoutons des couches personnalisées adaptées à notre problème de classification. Ces nouvelles couches comprennent une couche de pooling global, une normalisation batch, ainsi que des couches denses avec des fonctions d'activation appropriées.

Stratégie de fine-tuning et d'extraction de caractéristiques :

- **Stratégie de fine-tuning progressive :** L'entraînement du modèle se fait en deux phases :
 - **Phase 1 :** Nous entraînons uniquement les nouvelles couches ajoutées en gardant les couches pré-entraînées figées.
 - **Phase 2 :** Une fois les nouvelles couches stabilisées, nous dégelons progressivement certaines couches profondes du modèle afin de permettre une meilleure adaptation aux spécificités de notre dataset médical.
- **Optimisation et Précautions :** Pour éviter la destruction des poids pré-entraînés, nous utilisons un taux d'apprentissage réduit lors du fine-tuning. De plus, nous appliquons la batch normalization pour stabiliser l'apprentissage et prévenir l'overfitting.


Comparaison des performances avec le modèle CNN entraîné from scratch :

- Après avoir entraîné le modèle CNN classique from scratch et le modèle préentraîné avec fine-tuning, nous avons comparé leurs performances sur les mêmes jeux de données.
- Les critères de comparaison incluent :
 - Précision (Accuracy)
 - F1-Score
 - Matrice de confusion



Analyse des résultats et des gains en performance :

- Grâce au fine-tuning d'un modèle préentraîné, nous avons observé une augmentation notable de la précision, notamment dans les cas où notre dataset d'images médicales était relativement limité. Cette approche nous a également permis de mieux gérer le surapprentissage en utilisant des modèles plus robustes et généraux.



Comparaison des Deux Approches






Tableau comparatif des résultats :


Critère	<i>CNN (from scratch)</i>	<i>Modèle Pré-entraîné</i>
Précision (Accuracy)	99,5%	99,9%
F1-Score	XX%	YY%
Temps d'entraînement	3h heures et 30 minute	23 heures
Généralisation (Test)	100%	100%

- **Le modèle préentraîné**, bien qu'exigeant plus de ressources pour le fine-tuning, a permis d'atteindre presque les memes resultats.
- De plus, la rapidité d'entraînement a été consascré.




Démonstration en Temps Réel (Lab)





Conclusion et Perspectives



Synthèse des résultats obtenus :

- Nos résultats montrent que l'approche utilisant un modèle préentraîné avec fine-tuning a permis d'atteindre de meilleures performances par rapport au CNN entraîné from scratch, notamment en termes de précision (+0,4%) et de généralisation (100% pour les deux modèles).
- Cependant, le temps d'entraînement est considérablement plus long pour le modèle préentraîné (23 heures contre 3h30), ce qui peut poser des contraintes en fonction des ressources disponibles.

Améliorations possibles :

- **Optimisation des hyperparamètres** : Une recherche plus approfondie sur les hyperparamètres du modèle pourrait permettre d'atteindre des performances encore plus élevées.
- **Modèles plus avancés** : L'exploration d'architectures de modèles plus avancées comme EfficientNet ou d'autres modèles basés sur l'attention pourrait améliorer davantage les résultats.
- **Réduction du temps d'entraînement** : L'utilisation de techniques de quantification, de pruning ou d'accélération sur GPU/TPU pourrait permettre de réduire le temps de calcul du modèle préentraîné tout en maintenant sa haute précision.

Applications réelles et perspectives futures :

- Ce projet pourrait être utilisé dans des applications médicales réelles, comme la détection précoce de maladies ou le diagnostic automatisé basé sur des images médicales. Dans l'avenir, l'intégration de ces modèles dans des systèmes de santé pourrait améliorer la rapidité et la précision des diagnostics médicaux.

Applications réelles et perspectives futures :

- L'intégration de modèles d'intelligence artificielle dans le domaine médical ouvre de nouvelles opportunités pour améliorer le diagnostic et la prise en charge des patients.
- Il pourrait également assister les radiologues et spécialistes, en réduisant leur charge de travail et en proposant un second avis automatisé pour limiter les erreurs. Intégré aux systèmes de santé, ce type de solution permettrait d'optimiser la gestion des ressources médicales et d'améliorer l'accès aux soins.

Merci de votre attention

